

# Session-based Recommendation with Graph Neural Networks


Алина Плешкова

Лиза Вирко

Глеб Енгалыч

# Постановка задачи

- Классические рекомендации:
  - (user\_id, item\_id, feedback)
- Session-based рекомендации:
  - (item\_id, item\_id, item\_id, ..., ???)
- Могут быть разные действия. Упростим задачу -- все действия



# Почему не классические алгоритмы?

- Сессии часто анонимные.
- Один и тот же юзер в разные сессии ищет разное.
- Классические алгоритмы требуют знаний о юзере.




- Нужны алгоритмы, не опирающиеся на информацию о пользователе.

# Baselines

- POP - предлагает top-k самых популярных итемов из трейна.
- Item-KNN - ищет ближайший по косинусному расстоянию итем к предыдущим.
- BPR-MF - матричное разложение.
- FPMC - последовательное предсказание через марковские цепи.
- GRU4REC - rnn.
- NARM - rnn with attention.


# Session-based Recommendation with Graph Neural Networks



Cross-entropy loss

# Как построить граф одной сессии?



- Можно нормировать по графу из одной текущей сессии.
- Нормировать по графу из всех сессий.



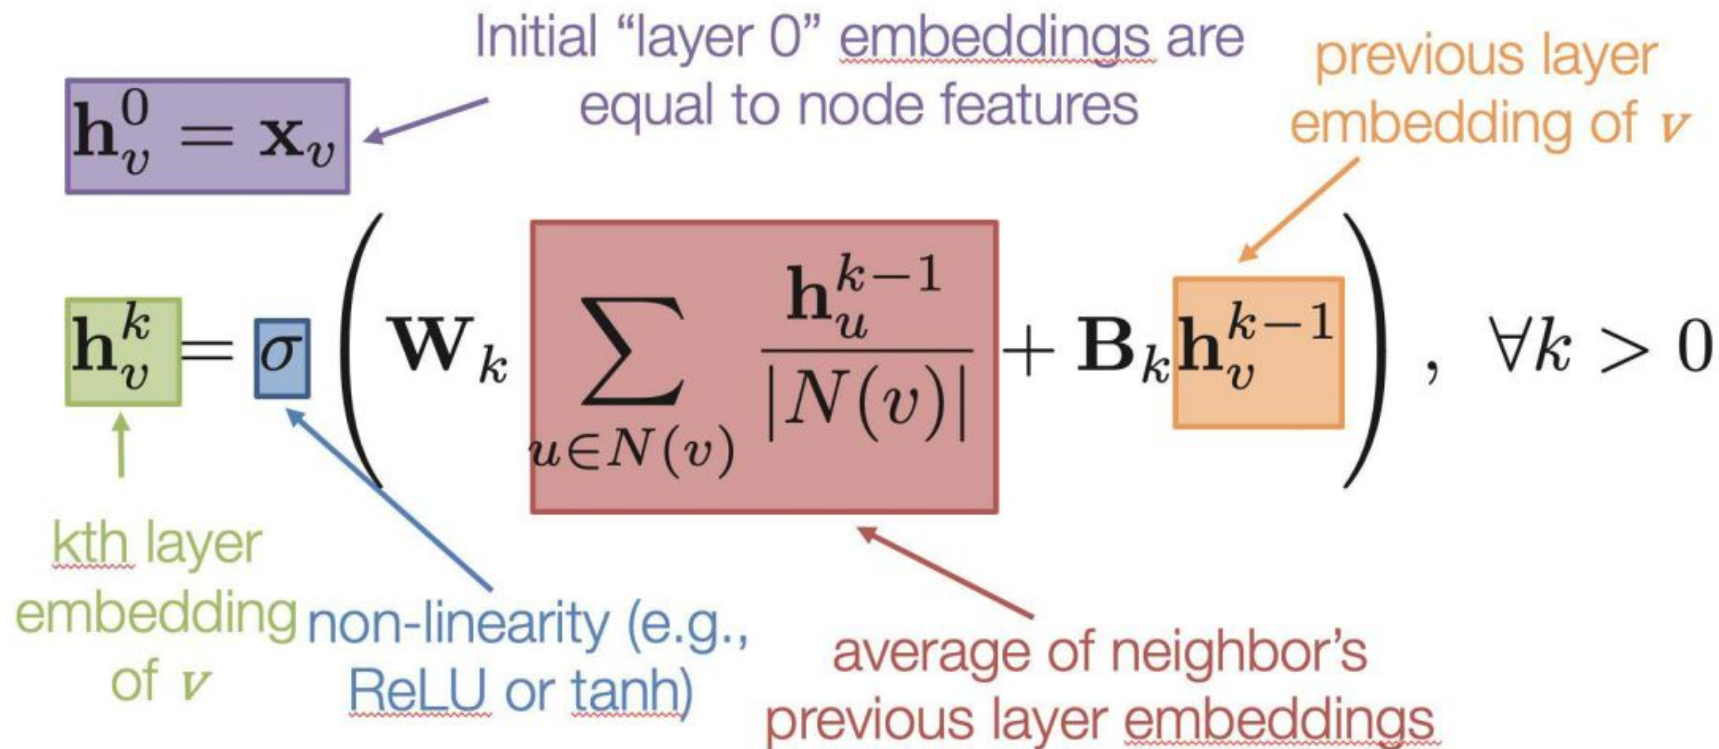
	Outgoing edges				Incoming edges			
	1	2	3	4	1	2	3	4
1	0	1	0	0	0	0	0	0
2	0	0	1/2	1/2	1/2	0	1/2	0
3	0	1	0	0	0	1	0	0
4	0	0	0	0	0	1	0	0

# GNN

**Идея:** Для создания эмбединга вершины нужно агрегировать информацию с нее и ее соседей.



# GNN: пересчет эмбедингов





## Эмбединги item-ов в нашем случае

$$\mathbf{a}_{s,i}^t = \mathbf{A}_{s,i}: [\mathbf{v}_1^{t-1}, \dots, \mathbf{v}_n^{t-1}]^\top \mathbf{H} + \mathbf{b},$$

$$\mathbf{z}_{s,i}^t = \sigma \left( \mathbf{W}_z \mathbf{a}_{s,i}^t + \mathbf{U}_z \mathbf{v}_i^{t-1} \right),$$

$$\mathbf{r}_{s,i}^t = \sigma \left( \mathbf{W}_r \mathbf{a}_{s,i}^t + \mathbf{U}_r \mathbf{v}_i^{t-1} \right),$$

$$\tilde{\mathbf{v}}_i^t = \tanh \left( \mathbf{W}_o \mathbf{a}_{s,i}^t + \mathbf{U}_o \left( \mathbf{r}_{s,i}^t \odot \mathbf{v}_i^{t-1} \right) \right)$$

$$\mathbf{v}_i^t = \left( 1 - \mathbf{z}_{s,i}^t \right) \odot \mathbf{v}_i^{t-1} + \mathbf{z}_{s,i}^t \odot \tilde{\mathbf{v}}_i^t,$$

# Как получить эмбединг сессии?

$$\mathbf{s} = [v_{s,1}, v_{s,2}, \dots, v_{s,n}]$$

- Берём эмбединг последнего итема в сессии  $\mathbf{s}_l = \mathbf{v}_n$

$$\alpha_i = \mathbf{q}^\top \sigma(\mathbf{W}_1 \mathbf{v}_n + \mathbf{W}_2 \mathbf{v}_i + \mathbf{c}),$$

- Делаем soft-attention слой:

$$\mathbf{s}_g = \sum_{i=1}^n \alpha_i \mathbf{v}_i,$$

- Ещё один линейный слой:  $\mathbf{s}_h = \mathbf{W}_3 [\mathbf{s}_l; \mathbf{s}_g]$

# Как сделать предсказание?

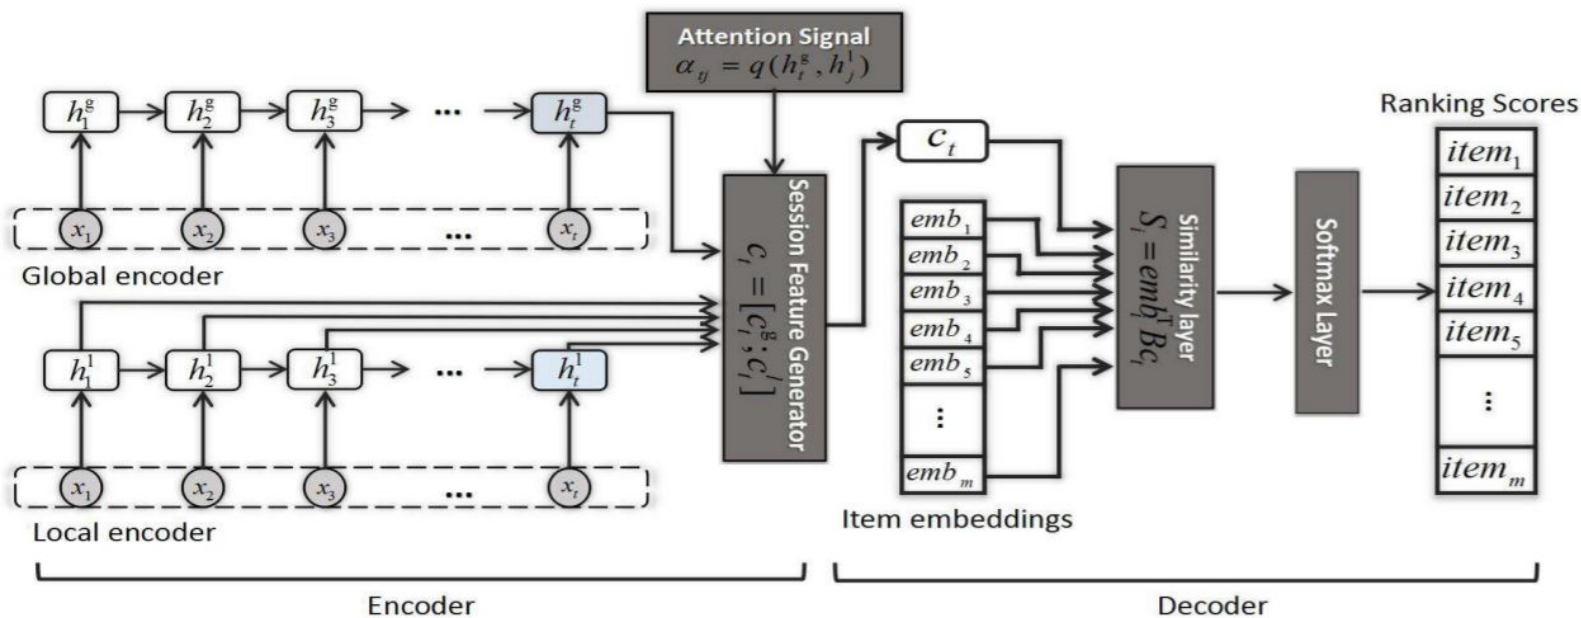
- Вычислили эмбединг сессии.
- Скалярно умножили на эмбединги каждого итема:  $\hat{\mathbf{z}}_i = \mathbf{s}_h^\top \mathbf{v}_i$ .
- Взяли софтмакс:

$$\hat{\mathbf{y}} = \text{softmax}(\hat{\mathbf{z}})$$

- Обучаем с помощью кросс-энтропии.

# Baseline: Neural Attentive Session-based Recommendation (NARM)

$$q(\mathbf{h}_t, \mathbf{h}_j) = \mathbf{v}^T \sigma(\mathbf{A}_1 \mathbf{h}_t + \mathbf{A}_2 \mathbf{h}_j)$$



# Датасеты

- yoochoose - RecSys Challenge 2015
  - убрали все сессии длины 1
  - убрали все итемы, которые встречаются реже 5 раз
  - дрогнули “плохие” сессии
- Осталось 7,981,580 сессий и 37,483 итема.
- Датасет всё ещё слишком большой, академики делают  $1/64$  и  $1/4$  (то есть, берут долю сессии с конца).

Statistics	<i>Yoochoose 1/64</i>	<i>Yoochoose 1/4</i>
# of training sessions	369,859	5,917,745
# of test sessions	55,898	55,898
# of items	16,766	29,618
Average length	6.16	5.71

- Diginetica - пропал из открытого доступа :(

# Метрики

- Precision@20 (recall@20)
- MRR@20

$$P@k = \frac{\#(\text{relevant items at } k)}{k}$$

$$R@k = \frac{\#(\text{relevant items at } k)}{\#(\text{relevant items})}$$

$$RR = \frac{1}{\text{rank of the first relevant item}}$$

# Результаты экспериментов

## Результаты статьи

Method	Yoochoose 1/64		Yoochoose 1/4		Diginetica	
	P@20	MRR@20	P@20	MRR@20	P@20	MRR@20
POP	6.71	1.65	1.33	0.30	0.89	0.20
S-POP	30.44	18.35	27.08	17.75	21.06	13.68
Item-KNN	51.60	21.81	52.31	21.70	35.75	11.57
BPR-MF	31.31	12.08	3.40	1.57	5.24	1.98
FPMC	45.62	15.01	—	—	26.53	6.95
GRU4REC	60.64	22.89	59.53	22.60	29.45	8.33
NARM	68.32	28.63	69.73	29.23	49.70	16.17
STAMP	68.74	29.67	70.44	30.00	45.64	14.32
SR-GNN	70.57	30.94	71.36	31.89	50.73	17.59

## Наши результаты

	Recall@20	MRR@20
NARM	69.11	29.72
SR-GNN	69.79	31.70

# А что с другими датасетами?

- Retailrocket recommender dataset

- не session-based, но user-based
- транзакции в интернет-магазине

- Для SR-GNN на коллабе не  
влез в оперативку (влезла лишь 1/32)

- результаты:

	Recall@20	MRR@20
NARM	14.73	5.15
SR-GNN	2.09	0.61

- SR-GNN успел за 8 часов пройти 4 эпохи (в статье обучается 30)
- NARM за 20 минут обучается на 500 эпох, но плохо, так попадает всегда в локальный минимум :(

- Академики  
набирают на  
ПОЛНОМ датасете:

Metrics	MRR@20	HR@20
S-SKNN	*0.345	*0.591
V-SKNN	0.338	0.573
S-KNN	0.337	0.583
BPR-MF	0.303	0.357
FPMC	0.273	0.320
SF-SKNN	0.260	0.358
SR	0.245	0.419
GRU4REC	0.243	0.480
AR	0.241	0.439
MC	0.230	0.359
SMF	0.225	0.459
IKNN	0.107	0.240
FISM	0.075	0.132
FOSSIL	0.022	0.058



# Попробуем Yoochoose 1/32

## Результаты статьи

### SRGNN

1/64: эпоха ~ 7 минут

1/32: эпоха ~ 2 часа

Method	Yoochoose 1/64		Yoochoose 1/4		Diginetica	
	P@20	MRR@20	P@20	MRR@20	P@20	MRR@20
POP	6.71	1.65	1.33	0.30	0.89	0.20
S-POP	30.44	18.35	27.08	17.75	21.06	13.68
Item-KNN	51.60	21.81	52.31	21.70	35.75	11.57
BPR-MF	31.31	12.08	3.40	1.57	5.24	1.98
FPMC	45.62	15.01	—	—	26.53	6.95
GRU4REC	60.64	22.89	59.53	22.60	29.45	8.33
NARM	68.32	28.63	69.73	29.23	49.70	16.17
STAMP	68.74	29.67	70.44	30.00	45.64	14.32
SR-GNN	70.57	30.94	71.36	31.89	50.73	17.59

## Наши результаты 1/64

	Recall@20	MRR@20
NARM	69.11	29.72
SR-GNN	69.79	31.70

## Наши результаты 1/32

	Recall@20	MRR@20
NARM	69.32	29.91
SR-GNN	70.3	31.98

# Результаты

- Результаты бейзлайна воспроизводимы!
- Результаты статьи воспроизводимы!
- На синтетически полученном датасете мы не смогли обучиться (нехватка ресурсов, долгое обучение)
- <https://github.com/herrbilbo/hse-recsys-project>